

Universidad del Valle de Guatemala

Data Science

Ing. Mario Barrientos



Laboratorio VI: Informe de Analítica de redes sociales

José Donado

Daniela Ramirez

Cindy Gualim


Resumen

El presente informe presenta el análisis de la estructura de participación de usuarios en YouTube a partir de dos conjuntos de datos: 293 videos y 406 comentarios recolectados sobre audiovisual guatemalteco (#quécometudiputado). La unidad de observación principal es el comentario. Al integrar los datos, se logró una asociación del 100% de los comentarios con sus videos respectivos; sin embargo, solo 19 de los 293 videos (6.5%) tenían comentarios. Es vital

destacar un sesgo de muestreo inicial: el 63% de los comentarios provienen de un solo canal periodístico: quorumgt.


Objetivo y metodología

Se realizó un diagnóstico de calidad, convirtiendo variables de conteo almacenadas como texto a formato numérico (e.g., visualizaciones y "me gusta") y tratando valores nulos sin eliminar filas. Para el análisis de texto, se creó un pipeline de procesamiento de lenguaje natural (NLP) que generó una versión "limpia" del texto: se convirtió a minúsculas, se removieron URLs, menciones, hashtags, signos de puntuación, números, emojis y palabras vacías (stopwords), y finalmente se lematizaron los términos. Resultados de limpieza: reducción del 43.9% en el volumen de caracteres y del 43.5% en el vocabulario. Solo 7 comentarios quedaron completamente vacíos de texto, pero no fueron eliminados ya que siguen representando una interacción (arista) válida para la red.




Análisis

Se observó que la participación se concentra intensamente en unos pocos videos y canales, como el de Quorum. Las métricas de popularidad (visualizaciones) siguen una distribución asimétrica de ley de potencia. Aunque existe una alta correlación (Spearman = 0.81) entre visualizaciones y cantidad de comentarios, la tasa de participación varía drásticamente, indicando que el nivel de interacción depende más de la temática del video que de su popularidad pura.



Se construyó una red bipartita no dirigida donde los nodos representan autores y videos, y las aristas representan la co-participación (el autor comentó en el video). El peso de la arista es la cantidad de comentarios. La red consta de 351 nodos y 343 aristas. A partir de esta, se generaron dos proyecciones:

- **Proyección Autor-Autor**: Conecta usuarios que comentaron en los mismos videos. Representa comunidades.
- **Proyección Video-Video**: Conecta videos que comparten a los mismos autores. Representa el flujo de audiencia.



La densidad de la red es extremadamente baja (0.054 en su bipartita). La estructura está dividida en componentes conexos fragmentados, pero existe una componente o video que agrupa el 81.5% de los nodos. La distribución de grados revela que el 97.3% de los autores participó en un solo video (son espectadores pasivos o de interacción única). Solo 9 autores actúan como puentes; conectando diferentes videos.

Interpretación de resultados

Existen sesgos significativos que restringen el alcance del análisis. Primero, un sesgo de selección y muestreo concentró más del 60 % de los datos analizados en un solo canal (Quorum), enfocando excesivamente el estudio hacia discusiones de índole periodístico y político. Segundo, la integración de los datos muestra un cruce muy pobre: de 293 videos, solo se capturó información de comentarios para 19, lo cual limita dramáticamente el marco poblacional. Tercero, las variables temporales y contadores de visualizaciones son instantáneas del momento de recolección.

Finalmente, dado que la variable `reply_count` no especifica el destinatario de una respuesta, es imposible modelar con precisión un flujo conversacional directo de autor a autor.

Descripción, Asociación e Inferencia

El informe presentado es estrictamente de naturaleza descriptiva y relacional. Aunque se hallaron asociaciones matemáticas y topológicas válidas, no se puede inferir causalidad aún. Dadas las fuertes limitaciones de muestreo, estas conclusiones carecen de validez poblacional y no pueden generalizarse a la totalidad de los usuarios de YouTube en Guatemala.

Conclusiones

1. La red es sumamente dispersa y dependiente de una reducida minoría de participantes hiperactivos y videos altamente populares que aglutinan la componente principal de la red.
2. La dinámica de consumo evidencia un marcado efecto estrella donde pocos nodos captan casi toda la interacción.
3. La naturaleza de los canales muestreados impregnó los hallazgos con un matiz fuertemente político, demostrando cómo entidades periodísticas operan como ejes de debate focalizados en comentarios que resuenan.
4. Las interacciones perfilan una base de usuarios mayoritariamente pasiva o lurkers según la clasificación del modelo por la falta de comentarios. Sin embargo, esto puede deberse a que los comentarios están restringidos para publicaciones gubernamentales. Con justificada razón.